

PROJETO INTERDISCIPLINAR

CTI: Plataforma Analítica de Planejamento Financeiro

Entrega 1 (Parcial)

Unidade Curricular: Projeto Interdisciplinar em Ciência de Dados

FECAP, 4º Semestre de Ciência da Computação

Projeto realizado em parceria com a CTI Global, 2º semestre de 2026

Integrantes do grupo

Artur Loreto

Breno Frederico Groba

Gustavo Archangelo

Luiz Antonio

Professor orientador: Eduardo Savino

Responsável por esta trilha: Gustavo Archangelo

1. Identificação da Fonte de Dados

O ponto de partida deste trabalho foi o arquivo Demonstrativo Fecap v3.csv, entregue pela CTI Global. Antes de sair mexendo nos dados, achamos importante entender bem o que estávamos recebendo.

- O arquivo está em CSV, separado por ponto e vírgula, com acentuação no padrão Latin 1 e sem linha de cabeçalho.
- Cada linha traz quatro informações: o ano, o cenário simulado, a conta contábil e o valor correspondente.
- No total são pouco mais de 1 milhão de linhas, cobrindo 12 anos, 1.200 cenários simulados, 3 demonstrativos financeiros e até 69 contas diferentes.
- É um dado interno da CTI, sem nenhuma informação pessoal, então não foi preciso pensar em anonimização.
- Um detalhe importante para interpretar os anos: essa projeção representa uma concessão, e o Ano 1 corresponde a 2027. Assim, o Ano 12 é 2038, o último ano do horizonte de concessão. Esse ponto é confirmado e ajuda a explicar alguns comportamentos diferentes que aparecem justamente nesse último ano, comentados mais adiante.

2. Coleta de Dados

Nessa etapa, o cuidado foi simplesmente carregar o arquivo do jeito que ele veio, sem alterar nada do conteúdo. Isso é importante porque, se mais para frente algo parecer estranho, dá para voltar e conferir contra a versão original.

Na prática, o arquivo trouxe algumas particularidades que precisaram ser tratadas já na hora da leitura:

- não tem cabeçalho, então tivemos que nomear as colunas na mão;
- a acentuação está em Latin 1, e não no UTF-8 que a gente costuma ver com mais frequência. Isso não é uma escolha nossa, é uma característica do próprio arquivo que a CTI exportou;
- os campos vêm todos entre aspas;
- e os valores foram lidos como texto mesmo, e não como número, porque estavam no formato brasileiro (tipo "1.234,56"), que o Python não reconhece de cara como número.

```
import pandas as pd
import csv

df_bruto = pd.read_csv(
    "Demonstrativo Fecap v3.csv",
    sep=";",
    header=None,
    names=["ano", "cenario", "conta", "valor"],
    encoding="latin-1",
    dtype=str,
    quoting=csv.QUOTE_ALL,
    keep_default_na=False,
)
```

Código usado para carregar o arquivo original pela primeira vez.

No fim, essa leitura trouxe 1.002.000 linhas e 4 colunas, batendo com o que já esperávamos do arquivo.

3. Descrição e Exploração dos Dados

Antes de limpar ou transformar qualquer coisa, passamos um tempo só olhando para os dados, para entender o que tinha ali dentro. Encontramos 12 anos diferentes, 1.200 cenários simulados e 69 nomes de conta distintos.

O que percebemos

- Um número que chamou atenção logo de cara: 43.200 linhas estavam com a coluna de conta em branco. No começo, parecia um problema, mas ao investigar vimos que essas linhas têm outra função dentro da planilha (isso é explicado com calma na seção 4).
- por outro lado, não encontramos nenhuma linha sem valor preenchido, o que foi um bom sinal;
- também notamos que o número de contas varia de ano para ano: os anos 1 e 2 têm 68 contas, os anos 3 a 11 têm 69, e o ano 12 tem só 42. Como o Ano 12 é 2038, o último ano do horizonte de concessão, essa redução está ligada ao encerramento de operações e à devolução de ativos previstos para o fim do contrato.

Quantidade de contas por ano

Ano	Quantidade de contas
Ano 1	68
Ano 2	68
Ano 3	69
Ano 4	69
Ano 5	69
Ano 6	69
Ano 7	69
Ano 8	69
Ano 9	69
Ano 10	69
Ano 11	69
Ano 12	42

4. Seleção de Dados

Voltando àquelas linhas com a conta em branco: percebemos que elas na verdade escondem duas coisas bem diferentes, e não um erro de preenchimento como parecia à primeira vista.

- parte delas são só marcadores de fim de bloco, sem nenhuma informação útil para a análise;
- a outra parte traz o peso de cada cenário simulado, algo que reaproveitamos mais para frente, na seção 6.

Com isso claro, separamos a planilha em três grupos:

```
conta_vazia = df_bruto["conta"] == ""
eh_zero = df_bruto["valor"].str.strip() == "0"

separadores = df_bruto.loc[conta_vazia & eh_zero].copy()
pesos = df_bruto.loc[conta_vazia & ~eh_zero].copy()
dados = df_bruto.loc[~conta_vazia].copy()
```

Separação da base bruta em três grupos: dados, pesos e separadores.

Só o grupo de dados contábeis reais, com o nome da conta preenchido, seguiu para as próximas etapas.

Grupo	Linhas	Proporção	O que aconteceu com elas
Total do arquivo	1.002.000	100%	-
Dados de conta	958.800	95,7%	Usadas na análise
Pesos de cenário	14.400	1,4%	Reaproveitadas na seção 6
Marcadores	28.800	2,9%	Descartadas, sem uso na análise

5. Limpeza e Uniformização

Um problema prático que encontramos: os valores estavam escritos no formato numérico brasileiro (por exemplo, "10.631.127.075,2579"), que o Python não interpreta como número sozinho. Então escrevemos uma função simples para fazer essa conversão, trocando o ponto de milhar e a vírgula decimal.

```
def texto_para_float(valor_texto):  
    if valor_texto is None or valor_texto.strip() == "":  
        return float("nan")  
    v = valor_texto.strip().replace(".", "").replace(",", ".")  
    return float(v)
```

Função usada para transformar os valores em texto no formato numérico brasileiro em números que o computador consegue calcular.

Aproveitamos também para corrigir nomes de conta com espaços repetidos, já que isso poderia fazer com que a mesma conta fosse contada como se fossem duas contas diferentes.

Duas contas chamaram atenção por terem nomes cortados na fonte original ("Emprést" e "Outros deb"). Decidimos mantê-las assim mesmo, já que não temos como adivinhar o nome completo sem perguntar para a CTI.

6. Derivação e Integração

Com os dados já limpos, criamos algumas colunas novas para facilitar as análises que vêm a seguir: o número do ano sem o texto "Ano", o tipo de demonstrativo financeiro (identificado pelo início do nome da conta) e o nome da conta já corrigido.

```
dados["ano_num"] = dados["ano"].str.extract(r"(\d+)").astype(int)  
dados["demonstrativo"] = dados["conta"].str.split(" - ",  
n=1).str[0].str.strip()
```

Criação das colunas ano_num e demonstrativo, derivadas das colunas originais.

Depois disso, juntamos essas informações com o peso de cada cenário simulado, aquele que tínhamos separado na etapa anterior. Assim, cada linha de dado contábil passou a carregar também o peso do seu cenário.

```
pesos_para_merge = pesos[["ano", "cenario", "peso_cenario"]]  
  
base_integrada = dados.merge(pesos_para_merge, on=["ano", "cenario"],  
how="left")  
base_integrada["cenario_num"] =  
base_integrada["cenario"].str.extract(r"(\d+)").astype(int)
```

Combinação dos dados contábeis com o peso de cada cenário.

Por que o peso do cenário importa

Vale explicar melhor esse ponto, porque ele é fácil de passar despercebido. O arquivo simula 1.200 cenários financeiros para cada ano, mas nem todos têm a mesma chance de acontecer: alguns são mais prováveis, outros representam situações mais extremas. O peso do cenário é justamente essa diferença de probabilidade.

Isso importa bastante para quem for calcular os indicadores financeiros mais para frente: se simplesmente somar os 1.200 cenários e dividir por 1.200, cenários raros acabam pesando tanto quanto os mais comuns, o que distorce o resultado. O certo é usar uma média ponderada pelo peso de cada cenário.

```
receita_esperada = soma(receita_do_cenario * peso_do_cenario) /  
soma(peso_do_cenario)  
  
# Forma que deve ser evitada, por ignorar o peso de cada cenário:  
receita_media_simples = soma(receita_do_cenario) / 1200
```

7. Formatação Final

Para fechar essa parte, organizamos a base por ano, cenário, demonstrativo e conta, e ajustamos alguns tipos de dado para deixar o arquivo mais leve.

```
base_final = base_integrada[  
    ["ano", "ano_num", "cenario", "cenario_num", "peso_cenario",  
     "demonstrativo", "conta", "conta_normalizada", "valor_num"]  
  
base_final["ano"] = base_final["ano"].astype("category")  
base_final["demonstrativo"] =  
base_final["demonstrativo"].astype("category")  
  
base_final = base_final.sort_values(  
    ["ano_num", "cenario_num", "demonstrativo", "conta"]  
) .reset_index(drop=True)
```

Seleção final das colunas, ajuste de tipos e ordenação da base.

Como o restante da equipe trabalha em planilha, essa base foi reorganizada num formato fácil de abrir no Excel: uma linha para cada cenário e ano, com uma coluna para cada conta contábil, já agrupadas por demonstrativo (BAL, DRE e FLU). O resultado foi salvo como `base_analitica_planilha.csv`.

```
base_planilha = base_final.pivot(  
    index=["cenario_num", "ano"],  
    columns="conta_normalizada",  
    values="valor"  
) .reset_index()  
  
base_planilha.to_csv("base_analitica_planilha.csv", index=False,  
encoding="utf-8-sig")
```

Reorganização da base em formato de planilha e exportação do arquivo final.

8. Verificação da Qualidade Final

Antes de dar essa etapa como concluída, quisemos ter mais certeza de que nada tinha se perdido pelo caminho. Para isso, rodamos cinco verificações automáticas sobre a base final, e o notebook inteiro foi executado do começo ao fim sem apresentar nenhum erro.

```
assert len(dados) + len(pesos) + len(separadores) == len(df_bruto)
assert base_final["valor"].isna().sum() == 0
assert base_final["peso_cenario"].isna().sum() == 0
assert (base_final["conta"] == "").sum() == 0
assert base_final["ano"].nunique() == 12
```

Verificações automáticas de qualidade aplicadas à base final.

Nº	O que foi verificado	Resultado
1	Nenhuma linha foi perdida ou duplicada durante o processo	Aprovado
2	Não existe nenhum valor em branco na coluna de valores	Aprovado
3	Todas as linhas receberam corretamente o peso do seu cenário	Aprovado
4	Nenhuma linha sem conta ficou na base final por engano	Aprovado
5	A base final tem os 12 anos e os 1.200 cenários esperados	Aprovado

9. Dicionário de Dados

Para facilitar o trabalho do restante da equipe, deixamos aqui uma descrição rápida de cada coluna do arquivo final (base_analitica_planilha.csv). Cada linha da planilha representa um cenário simulado em um determinado ano, e cada conta contábil aparece como uma coluna separada.

Coluna	Descrição
Cenário	Identificação do cenário simulado (Cenário 1 a Cenário 1.200)
Ano	Ano da simulação (de Ano 1 a Ano 12)
BAL - [nome da conta]	Valor daquela conta do Balanço Patrimonial, no cenário e ano da linha
DRE - [nome da conta]	Valor daquela conta da Demonstração de Resultado, no cenário e ano da linha
FLU - [nome da conta]	Valor daquela conta do Fluxo de Caixa, no cenário e ano da linha

As colunas de conta ficam agrupadas automaticamente nessa ordem (BAL, depois DRE, depois FLU), porque o nome de cada uma começa com o prefixo do demonstrativo a que pertence. Como o ano 12 tem apenas 42 contas, contra 68 ou 69 nos demais anos, as colunas das contas que não existem nesse ano aparecem em branco só nas linhas do ano 12, o que é esperado (ver seção 10).

10. Pontos de Atenção

- o ano 12 tem só 42 contas, bem menos que os demais anos. Isso está diretamente ligado ao fato de esse ano corresponder a 2038, o último do horizonte de concessão: a redução reflete o encerramento das operações e a devolução de ativos previstos para o fim do contrato. Ainda assim, vale ter cautela ao comparar o ano 12 diretamente com os outros em qualquer análise;
- duas contas vieram com nome cortado na planilha original ("Emprést" e "Outros deb"). Preferimos mantê-las como estão, já que não dava para adivinhar o nome completo sem falar com a CTI;
- também encontramos uma margem de EBITDA de cerca de 95,6% no ano 12, bem acima do que seria esperado nos demais anos. Como esse é o último ano da concessão, essa distorção provavelmente está ligada ao mesmo processo de encerramento, mas o valor exato ainda vale a pena confirmar com a CTI antes da próxima entrega;

- por fim, as 43.200 linhas sem conta preenchida na planilha original não indicam um problema de qualidade. Elas cumprem uma função específica (pesos de cenário e marcadores de bloco) e foram tratadas dessa forma desde a etapa de seleção.